

PRACTICAL AWS GENERATIVE AI & RAG LAB

Projeto prático desenvolvido para estudar, implementar e validar conhecimentos em serviços de Inteligência Artificial da AWS, com foco em Generative AI, Retrieval-Augmented Generation (RAG), arquitetura cloud e boas práticas de segurança.

O projeto não tem como objetivo ser uma plataforma comercial. Ele funciona como um laboratório técnico de portfólio, no qual cada etapa representa uma competência prática implementada e validada na AWS.

OBJETIVOS

Este projeto busca demonstrar, na prática:

- utilização do Amazon Bedrock;
- construção de uma Knowledge Base;
- implementação de Retrieval-Augmented Generation (RAG);
- integração de dados armazenados no Amazon S3;
- utilização de embeddings para recuperação semântica;
- integração entre serviços AWS;
- aplicação de princípios de IAM e menor privilégio;
- avaliação de qualidade de aplicações de IA generativa;
- observabilidade e análise de execução;
- posteriormente, infraestrutura como código e automação de deployment.

A evolução do projeto será incremental: cada versão adicionará uma capacidade arquitetural ou uma prática de engenharia e será documentada com seus respectivos resultados.

PROBLEMA TÉCNICO

Modelos de linguagem possuem conhecimento geral, mas uma aplicação pode precisar responder utilizando um conjunto específico de documentos.

Neste projeto, o objetivo é avaliar uma arquitetura na qual informações externas são recuperadas de uma base de conhecimento e utilizadas como contexto para a geração da resposta.

O fluxo implementado utiliza o padrão RAG:

Documentos


|
v

Amazon S3

|
v

Amazon Bedrock Knowledge Base

|



O Amazon Bedrock Knowledge Bases permite recuperar os trechos mais relevantes de uma fonte de dados e, por meio de RetrieveAndGenerate, utilizar esses trechos para gerar uma resposta em linguagem natural com citações das fontes recuperadas.

ARQUITETURA - V1

A primeira versão foi construída utilizando os seguintes componentes:

Componente	Serviço AWS	Função
---	---	---
Armazenamento	Amazon S3	Armazenar os documentos utilizados pela KB
Orquestração RAG	Amazon Bedrock Knowledge Bases	Ingestão, indexação e recuperação
Embeddings	Amazon Titan Text Embeddings V2	Representação vetorial dos documentos
Vector Store	Managed Vector Storage	Armazenamento dos embeddings
Geração	Amazon Bedrock / Nova Micro	Geração da resposta baseada no contexto recuperado
Identidade	AWS IAM	Permissões utilizadas pela Knowledge Base
Observabilidade	Amazon CloudWatch	Logs e métricas disponíveis para acompanhamento

A AWS recomenda atualmente o Amazon Bedrock Managed Knowledge Base quando se busca uma experiência gerenciada para ingestion, storage, indexing e retrieval, reduzindo a necessidade de administrar a infraestrutura subjacente.

IMPLEMENTAÇÃO DA V1

1. Amazon S3

Foi criado um bucket S3 para servir como fonte de dados da Knowledge Base.

Amazon S3
-- documento de estudo

A integração S3 -> Knowledge Base permite que os objetos armazenados no bucket sejam ingeridos pela base de conhecimento. A integração também suporta sincronizações incrementais quando conteúdos são adicionados, modificados ou removidos.

2. Amazon Bedrock Knowledge Base

Foi criada uma Managed Knowledge Base com armazenamento vetorial gerenciado.

Configurações principais da V1:

Knowledge Base:
ai-study-assistant-kb

Embedding:
Amazon Titan Text Embeddings V2

Vector type:
FLOAT32

Vector dimensions:
1024

Data source:
Amazon S3

Parser:
Managed Parser

Chunking:
Default

O Titan Text Embeddings V2 é um modelo suportado pelo Amazon Bedrock Knowledge Bases para geração de embeddings vetoriais.

3. Ingestion

Após a criação da fonte de dados, foi executada uma sincronização manual.

O pipeline de ingestão transforma os documentos em conteúdo processável e posteriormente em embeddings que podem ser utilizados para recuperação semântica.

Fluxo conceitual:

```
PDF
|
v
Parsing
|
v
Text chunks
|
v
Embeddings
```

|
v
Vector storage

4. Retrieval-Augmented Generation

A KB foi testada diretamente pelo console do Amazon Bedrock.

As consultas retornaram:

resposta gerada pelo modelo;
fragmentos relevantes do documento;
referências às fontes utilizadas.

Isso validou o funcionamento básico do pipeline RAG.

Query
|
v
Knowledge Base
|
v
Relevant source chunks
|
v
Foundation Model
|
v
Generated response
|
v
Source citations

O Amazon Bedrock disponibiliza as operações Retrieve e RetrieveAndGenerate. A primeira retorna os fragmentos relevantes; a segunda combina recuperação e geração e pode retornar citações dos fragmentos utilizados.

COMPETÊNCIAS AWS VALIDADAS NA V1

A V1 foi utilizada para validar conhecimento prático sobre:

Amazon S3

criação de bucket;
armazenamento de objetos;
integração com outro serviço AWS;
seleção de uma fonte S3 para ingestão.

Amazon Bedrock

Knowledge Bases;
Foundation Models;
embeddings;
RAG;
recuperação de contexto;
geração fundamentada em documentos.

IAM

criação de service role;
entendimento da relação entre serviço AWS e IAM role;
concessão de permissões necessárias para acesso aos recursos.

CloudWatch

identificação de mecanismos de observabilidade associados à aplicação;
utilização de logs para diagnóstico e acompanhamento.

RESULTADO DA V1

A V1 conseguiu validar o seguinte fluxo:

[OK] Documento armazenado no S3
[OK] S3 conectado ao Bedrock Knowledge Base
[OK] Documento ingerido
[OK] Documento convertido em embeddings
[OK] Embeddings armazenados no vector store gerenciado
[OK] Consulta realizada com sucesso
[OK] Fragmentos relevantes recuperados
[OK] Resposta generativa produzida
[OK] Fontes recuperadas apresentadas na resposta

Evidência

Os testes realizados diretamente no Amazon Bedrock retornaram tanto a resposta gerada quanto os source fragments utilizados pelo sistema.

Isso demonstra que o experimento não se limita a uma chamada direta a um LLM: existe uma etapa de retrieval sobre dados externos antes da geração.

O QUE ESTA V1 NÃO PRETENDE DEMONSTRAR

A V1 deliberadamente não implementa uma aplicação completa.

Não fazem parte desta etapa:

- [X] Frontend
- [X] API pública
- [X] Sistema de usuários
- [X] Histórico de conversas
- [X] Banco de dados de aplicação
- [X] CI/CD
- [X] Infrastructure as Code
- [X] Guardrails
- [X] Testes automatizados
- [X] Avaliação quantitativa

Esses componentes serão adicionados somente quando forem necessários para validar novas competências.

ROADMAP TÉCNICO

V1 - RAG Fundamentals [OK]

S3

- v
- Bedrock Knowledge Base
- v
- Embeddings
- v
- Vector Storage
- v
- Retrieval
- v
- Foundation Model

Status: Concluída

V2 - Application Integration

Objetivo: integrar a Knowledge Base com código de aplicação.

- Client
- v
 - API Gateway
 - v
 - AWS Lambda
 - v
 - Bedrock Knowledge Base
 - v
 - Response

Competências:

AWS Lambda;
API Gateway;
Boto3;
IAM;
integração entre serviços;
tratamento de erros;
estruturação de API.

V3 - Security & Responsible AI

Adicionar mecanismos de proteção e controle:

Amazon Bedrock Guardrails;
prompt injection testing;
validação de entradas;
controle de permissões;
princípio do menor privilégio.

V4 - Evaluation

Criar um conjunto controlado de perguntas e avaliar:

qualidade da recuperação;
relevância dos documentos recuperados;
qualidade das respostas;
taxa de respostas incorretas;
comportamento com perguntas fora da base.

O objetivo será transformar o projeto em um experimento mensurável, em vez de apenas uma demonstração funcional.

V5 - Infrastructure as Code

Reproduzir a infraestrutura utilizando:

Terraform

Objetivo:

Infrastructure

|
v

Terraform

|
v

V6 - CI/CD & Engineering Practices

Adicionar:

GitHub Actions;
testes automatizados;
validações;
deployment automatizado;
controle de ambientes.

DECISÕES ARQUITETURAIS

As decisões tomadas durante o desenvolvimento serão registradas em docs/architecture.md.

A intenção é documentar não apenas o que foi utilizado, mas também:

> por que determinada tecnologia foi escolhida e qual problema ela resolve.

Isso permitirá avaliar o projeto também como um exercício de arquitetura cloud.

DOCUMENTAÇÃO

Documento	Descrição
architecture.md	Arquitetura e decisões técnicas
development-log.md	Histórico da evolução do projeto

SEGURANÇA

Este repositório não contém:

credenciais AWS;
access keys;
secret keys;
tokens;
arquivos .env;
informações privadas da conta AWS;
documentos proprietários utilizados durante os testes.

Os documentos utilizados durante o experimento permanecem armazenados na infraestrutura AWS e não são distribuídos neste repositório.

OBJETIVO DE PORTFÓLIO

Este projeto foi desenvolvido como uma demonstração prática de engenharia de IA na AWS.

O principal objetivo não é quantidade de serviços utilizados, mas demonstrar a capacidade de:

- Entender um problema
 - v
- Escolher serviços AWS adequados
 - v
- Construir a solução
 - v
- Testar o comportamento
 - v
- Analisar os resultados
 - v
- Documentar decisões
 - v
- Evoluir a arquitetura

Cada nova versão será considerada concluída somente após a respectiva capacidade técnica ser implementada e validada.

STATUS

Em desenvolvimento - V1 concluída

[#####-----] RAG Fundamentals

V1	#####	100%
V2	-----	0%
V3	-----	0%
V4	-----	0%
V5	-----	0%
V6	-----	0%

AUTOR

Felipe Lelis Zancanela Rabello

Computer Engineering student focused on Artificial Intelligence, Generative AI, Cloud Computing

and AWS.

> This repository is an evolving technical laboratory. The architecture, implementation and documentation will change as new AWS capabilities and engineering practices are evaluated.